

ANALISIS SENTIMEN ULASAN PRODUK SHOPEE
MENGUNAKAN METODE BAG OF WORDS DAN TF-IDF
DENGAN ALGORITMA NAIVE BAYES



Disusun Oleh:
Exeldus Moreno / 2301020074

Dosen Pengampu:
IDA BAGUS KRESNA SUDIATMIKA, S.KOM., M.T.

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI DAN DESAIN
PRIMAKARA UNIVERSITY
TAHUN AJARAN 2025/2026

1. Latar Belakang

Natural Language Processing (NLP) merupakan salah satu cabang dari kecerdasan buatan yang berfokus pada kemampuan komputer dalam memahami, mengolah, dan menganalisis bahasa manusia. Salah satu implementasi yang paling banyak digunakan dalam NLP adalah analisis sentimen, yaitu proses untuk mengklasifikasikan opini atau emosi dalam teks ke dalam kategori tertentu seperti positif, negatif, atau netral.

Seiring dengan perkembangan teknologi digital, platform e-commerce seperti Shopee menjadi salah satu sumber utama bagi pengguna dalam memberikan ulasan terhadap produk yang mereka beli. Ulasan tersebut mengandung informasi penting yang mencerminkan pengalaman dan kepuasan pengguna. Namun, jumlah data yang sangat besar membuat analisis secara manual menjadi tidak efisien, sehingga diperlukan pendekatan otomatis menggunakan teknik NLP.

Meskipun analisis sentimen telah banyak dilakukan, terdapat beberapa tantangan yang sering muncul, seperti ketidakseimbangan distribusi data antar kelas dan kesulitan dalam mengidentifikasi kelas netral yang cenderung tidak memiliki kata kunci yang spesifik. Hal ini dapat menyebabkan model klasifikasi menjadi bias terhadap kelas tertentu dan menurunkan performa pada kelas minoritas.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk membangun sistem analisis sentimen terhadap ulasan produk Shopee berbahasa Indonesia menggunakan pendekatan machine learning. Metode yang digunakan meliputi dua teknik representasi teks, yaitu Bag of Words (BoW) dan Term Frequency–Inverse Document Frequency (TF-IDF), yang kemudian dibandingkan performanya menggunakan algoritma klasifikasi Multinomial Naive Bayes.

Melalui penelitian ini, diharapkan dapat diperoleh pemahaman yang lebih mendalam mengenai pengaruh metode representasi teks terhadap performa model, khususnya dalam menangani data dengan distribusi yang tidak seimbang dan karakteristik bahasa yang beragam.

2. Metodologi

2.1 Dataset

Dataset yang digunakan dalam penelitian ini diperoleh dari Kaggle, berupa ulasan produk Shopee berbahasa Indonesia. Dataset terdiri dari lebih dari 3000 data ulasan dengan dua atribut utama, yaitu:

- **content:** berisi teks ulasan pengguna
- **score:** berisi rating yang diberikan pengguna terhadap produk

Dataset ini dipilih karena merepresentasikan data nyata dari pengguna e-commerce dengan variasi bahasa yang cukup beragam.

2.2 Pelabelan Data

Pelabelan sentimen dilakukan berdasarkan nilai rating yang tersedia pada dataset. Proses ini bertujuan untuk mengubah data numerik menjadi kategori klasifikasi.

Skema pelabelan yang digunakan adalah sebagai berikut:

- Rating 1–2 → **negatif**
- Rating 3 → **netral**
- Rating 4–5 → **positif**

Pendekatan ini digunakan karena rating dianggap sebagai representasi langsung dari tingkat kepuasan pengguna.

2.3 Text Preprocessing

Tahap preprocessing dilakukan untuk membersihkan dan menyiapkan data teks sebelum digunakan dalam proses modeling. Tahapan yang dilakukan meliputi:

1. **Cleaning**
Menghapus URL, tanda baca, angka, dan karakter khusus serta mengubah teks menjadi huruf kecil (lowercase).
2. **Tokenization**
Memecah teks menjadi unit kata (token) menggunakan library NLTK.
3. **Stopword** **Removal**
Menghapus kata-kata umum yang tidak memiliki makna signifikan menggunakan library Sastrawi.
4. **Stemming**
Mengubah kata ke bentuk dasar menggunakan algoritma stemming dari Sastrawi untuk mengurangi variasi kata.

Tahapan ini penting untuk meningkatkan kualitas fitur yang akan digunakan dalam model.

2.4 Representasi Teks

Dalam penelitian ini digunakan dua metode representasi teks, yaitu:

1. **Bag of Words (BoW)**
Mengubah teks menjadi representasi numerik berdasarkan frekuensi kemunculan kata.
2. **TF-IDF (Term Frequency–Inverse Document Frequency)**
Memberikan bobot pada kata berdasarkan tingkat kepentingannya dalam dokumen dibandingkan seluruh dataset.

Parameter yang digunakan pada kedua metode:

- **max_features = 5000** → membatasi jumlah fitur agar model lebih efisien
- **min_df = 5** → mengabaikan kata yang jarang muncul
- **max_df = 0.8** → mengabaikan kata yang terlalu umum

Penggunaan dua metode ini bertujuan untuk membandingkan efektivitas representasi teks dalam analisis sentimen.

2.5 Modeling

Model yang digunakan dalam penelitian ini adalah **Multinomial Naive Bayes**, yang merupakan algoritma klasifikasi berbasis probabilitas.

Model ini dipilih karena:

- cocok untuk data teks berbasis frekuensi
- memiliki performa yang baik pada klasifikasi dokumen
- efisien dalam komputasi

Model dilatih menggunakan data latih dan diuji menggunakan data uji yang diperoleh dari proses pembagian dataset.

2.6 Evaluasi

Evaluasi model dilakukan untuk mengukur performa klasifikasi menggunakan beberapa metrik, yaitu:

- **Accuracy** → mengukur persentase prediksi yang benar
- **Precision** → mengukur ketepatan prediksi pada setiap kelas
- **Recall** → mengukur kemampuan model dalam menemukan data yang benar
- **F1-score** → mengukur keseimbangan antara precision dan recall
- **Confusion Matrix** → menganalisis kesalahan prediksi secara detail

Penggunaan berbagai metrik ini bertujuan untuk memberikan evaluasi yang lebih komprehensif, terutama dalam kondisi data yang tidak seimbang.

3. Hasil Eksperimen

3.1 Distribusi Data

Berdasarkan visualisasi distribusi label, terlihat bahwa dataset memiliki ketidakseimbangan kelas (imbalanced data). Kelas positif mendominasi jumlah data, diikuti oleh kelas negatif, sedangkan kelas netral memiliki jumlah paling sedikit.

Ketidakseimbangan ini berpotensi menyebabkan model cenderung bias terhadap kelas mayoritas, sehingga performa pada kelas minoritas, khususnya netral, menjadi kurang optimal.

3.2 Hasil Model Bag of Words

Model klasifikasi menggunakan representasi Bag of Words (BoW) menghasilkan akurasi sekitar 75%. Model ini mampu mengklasifikasikan ketiga kelas sentimen, yaitu negatif, netral, dan positif.

Namun, performa pada kelas netral masih tergolong rendah jika dibandingkan dengan kelas lainnya. Hal ini terlihat dari nilai recall dan f1-score yang lebih kecil, yang menunjukkan bahwa model masih mengalami kesulitan dalam mengenali pola pada data netral.

Meskipun demikian, BoW menunjukkan performa yang relatif stabil karena masih mampu mendeteksi semua kelas tanpa mengabaikan kelas tertentu.

3.3 Hasil Model TF-IDF

Model yang menggunakan representasi TF-IDF menghasilkan akurasi yang sedikit lebih tinggi, yaitu sekitar 77%. Hal ini menunjukkan bahwa TF-IDF mampu meningkatkan performa secara keseluruhan.

Namun, terdapat kelemahan signifikan pada model ini, yaitu kegagalan dalam mengklasifikasikan kelas netral. Nilai recall untuk kelas netral sebesar 0 menunjukkan bahwa model tidak mampu mengenali data netral sama sekali.

Fenomena ini mengindikasikan bahwa meskipun TF-IDF efektif dalam menonjolkan kata-kata penting, metode ini kurang mampu menangkap karakteristik kelas yang tidak memiliki kata kunci yang spesifik.

3.4 Visualisasi

Beberapa visualisasi digunakan untuk mendukung analisis hasil eksperimen, antara lain:

- Distribusi** **Label**
Digunakan untuk menunjukkan ketidakseimbangan jumlah data pada setiap kelas sentimen.
- WordCloud**
Digunakan untuk menampilkan kata-kata yang paling sering muncul dalam dataset, sehingga memberikan gambaran umum mengenai karakteristik teks.
- Confusion** **Matrix**
Digunakan untuk menganalisis kesalahan prediksi model secara lebih detail, termasuk pola kesalahan antar kelas dan kecenderungan bias model.

Visualisasi ini membantu dalam memahami perilaku model serta mengidentifikasi kelemahan yang tidak terlihat hanya dari nilai evaluasi numerik.

4. Analisis Perbandingan Metode

Berdasarkan hasil eksperimen yang telah dilakukan, terlihat adanya perbedaan karakteristik performa antara metode Bag of Words (BoW) dan TF-IDF dalam melakukan klasifikasi sentimen.

Model dengan representasi TF-IDF menghasilkan nilai accuracy yang lebih tinggi dibandingkan BoW. Hal ini menunjukkan bahwa TF-IDF lebih efektif dalam menyoroti kata-kata yang memiliki bobot penting dalam suatu dokumen, sehingga mampu meningkatkan performa klasifikasi secara keseluruhan.

Namun, peningkatan accuracy tersebut tidak diikuti dengan performa yang merata pada seluruh kelas. Model TF-IDF gagal dalam mengklasifikasikan kelas netral, yang ditunjukkan dengan nilai recall sebesar 0. Hal ini mengindikasikan bahwa model sama sekali tidak mampu mengenali karakteristik dari kelas netral.

Fenomena ini dapat dijelaskan dari cara kerja TF-IDF yang memberikan bobot rendah pada kata-kata yang sering muncul di banyak dokumen. Kelas netral umumnya tidak memiliki kata kunci yang spesifik atau emosional, melainkan menggunakan kata-kata umum yang juga muncul pada kelas positif dan negatif. Akibatnya, fitur yang merepresentasikan kelas netral menjadi kurang signifikan dalam proses pembelajaran model.

Sebaliknya, metode Bag of Words yang hanya menghitung frekuensi kemunculan kata tanpa mempertimbangkan distribusi global, cenderung lebih stabil dalam mempertahankan informasi dari semua kelas, termasuk kelas netral. Hal ini menyebabkan BoW mampu mendeteksi seluruh kelas meskipun dengan nilai accuracy yang sedikit lebih rendah.

Selain faktor representasi teks, distribusi data yang tidak seimbang juga berkontribusi terhadap performa model. Dominasi kelas positif dalam dataset menyebabkan model memiliki kecenderungan bias terhadap kelas tersebut. Hal ini terlihat pada confusion matrix, di mana banyak data dari kelas netral dan negatif diprediksi sebagai positif.

Dengan demikian, dapat disimpulkan bahwa meskipun TF-IDF unggul dalam meningkatkan accuracy, metode ini kurang optimal dalam menangani kelas dengan karakteristik yang tidak memiliki fitur dominan. Sebaliknya, BoW lebih mampu menjaga keseimbangan performa antar kelas, sehingga lebih sesuai digunakan pada dataset dengan distribusi yang tidak seimbang.

5. Kesimpulan

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, dapat disimpulkan bahwa metode representasi teks memiliki pengaruh yang signifikan terhadap performa model analisis sentimen.

Metode TF-IDF menunjukkan performa yang lebih baik dari segi accuracy karena mampu menonjolkan kata-kata yang memiliki bobot penting dalam dokumen. Namun, metode ini tidak mampu mengenali kelas netral, yang ditunjukkan dengan nilai recall sebesar 0. Hal ini disebabkan oleh karakteristik kelas netral yang tidak memiliki kata kunci yang spesifik, sehingga fitur yang dihasilkan oleh TF-IDF menjadi kurang representatif.

Sebaliknya, metode Bag of Words menghasilkan performa yang lebih seimbang antar kelas meskipun memiliki nilai accuracy yang sedikit lebih rendah. Hal ini menunjukkan bahwa BoW lebih stabil dalam menangani data dengan distribusi yang tidak seimbang.

Selain itu, ketidakseimbangan jumlah data pada masing-masing kelas juga menjadi faktor penting yang mempengaruhi performa model. Dominasi kelas positif menyebabkan model cenderung bias terhadap kelas tersebut, sehingga performa pada kelas minoritas menjadi menurun.

Dengan demikian, pemilihan metode representasi teks tidak hanya harus mempertimbangkan nilai accuracy, tetapi juga kemampuan model dalam menangani seluruh kelas secara seimbang.

Untuk pengembangan selanjutnya, disarankan:

1. Menggunakan teknik penyeimbangan data seperti oversampling atau undersampling untuk mengatasi ketidakseimbangan kelas.
2. Mengembangkan fitur yang lebih kontekstual seperti Word Embeddings (Word2Vec, FastText) atau model berbasis transformer (BERT) agar mampu menangkap makna kata secara lebih mendalam.
3. Menggunakan kombinasi fitur seperti n-gram untuk meningkatkan kemampuan model dalam memahami konteks kalimat.

6. Referensi

Jurafsky, D., & Martin, J. H. (2009). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Pearson.

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.

Scikit-learn Developers. (2024). *Scikit-learn: Machine Learning in Python*. Diakses dari <https://scikit-learn.org/>

Kaggle. (2026). *Shopee Product Review Dataset (Indonesia)*.

Diakses dari <https://www.kaggle.com/datasets/ahmadseloabadi/shoppe-app-reviews-from-google-play-store>